

Klasyfikacja danych i porównanie modeli predykcyjnych

Katarzyna Bednarkiewicz, Ewelina Dąbrowa

2026-06-03

Spis treści

1	Klasyfikacja na bazie modelu regresji liniowej.	2
1.1	Analizowane dane.	2
1.2	Podział danych na zbiór uczący i testowy	2
1.3	Konstrukcja klasyfikatora i wyznaczenie prognoz	2
1.4	Ocena jakości modelu	2
1.5	Budowa modelu liniowego dla rozszerzonej przestrzeni cech	4
2	Porównanie metod klasyfikacji.	7
2.1	Wybór i zapoznanie się z danymi.	7
2.2	Cel analizy.	8
2.3	Wstępna analiza danych.	9
2.4	Ocena dokładności klasyfikacji i porównanie metod.	14
2.5	Różne parametry i różne podzbiory cech.	20
2.6	Końcowe wnioski - podsumowanie.	25

1 Klasyfikacja na bazie modelu regresji liniowej.

1.1 Analizowane dane.

Ramka danych *iris* pochodzi z pakietu bazowego R - *datasets*. Zbiór danych zawiera wyniki pomiarów uzyskanych dla trzech gatunków irysów (*setosa*, *versicolor* i *virginica*). Pomiarzy dotyczą długości oraz szerokości dwóch części kwiatu: działki kielicha (ang. *sepal*) oraz płatek (ang. *petal*). Mamy $K = 3$ klasy oraz $p = 4$ zmienne objaśniające: **Petal.Length**, **Petal.Width**, **Sepal.Length**, **Sepal.Width**. Każda klasa zawiera po 50 obserwacji.

1.2 Podział danych na zbiór uczący i testowy

Dzielimy losowo zbiór danych na część uczącą oraz testową w proporcji 70% - zbiór uczący, 30% - zbiór testowy.

1.3 Konstrukcja klasyfikatora i wyznaczenie prognoz


Konstruujemy klasyfikator za pomocą modelu regresji liniowej, wykorzystując funkcję *lm()*. Stosujemy kodowanie klas przy użyciu zmiennych binarnych.

1.4 Ocena jakości modelu

Dla zbudowanego modelu wyznaczamy macierze pomyłek oraz błąd klasyfikacji na zbiorze uczącym oraz testowym.

	setosa	versicolor	virginica
pred. setosa	36	0	0
pred. versicolor	0	18	4
pred. virginica	0	14	33

Tabela 1: Tabela pomyłek dla zbioru treningowego




Rysunek 1: Prognozy dla zbioru treningowego

Na podstawie wyników z macierzy pomyłek dla zbioru treningowego (Tabela 1) oraz Rysunku 1, widzimy, że model wręcz bezbłędnie radzi sobie z klasyfikacją irysów z gatunku setosa, jednak dla gatunków versicolor i virginica obserwujemy maskowanie się klas. Skuteczność dla zbioru treningowego wyniosła 82.86%, co oznacza błąd klasyfikacji równy 17.14%.

	setosa	versicolor	virginica
pred. setosa	14	0	0
pred. versicolor	0	13	1
pred. virginica	0	5	12

Tabela 2: Tabela pomyłek dla zbioru testowego



Rysunek 2: Prognozy dla zbioru testowego


Na podstawie wyników z macierzy pomyłek dla zbioru treningowego (Tabela 2) oraz Rysunku 2, widzimy, że model ponownie bardzo dobrze radzi sobie z klasyfikacją irysów z gatunku setosa, jednak dla gatunków versicolor i virginica zachodzi częściowe maskowanie się klas. Skuteczność modelu dla danych testowych wynosi 86.67% (błąd równy 13.33%).

1.5 Budowa modelu liniowego dla rozszerzonej przestrzeni cech

Konstruujemy model, tym razem po uzupełnieniu wyjściowych cech o składniki wielomianowe stopnia 2. Dla zbudowanego modelu wyznaczamy macierze pomyłek oraz błąd klasyfikacji na zbiorze uczącym oraz testowym.

	setosa	versicolor	virginica
pred. setosa	36	0	0
pred. versicolor	0	32	1
pred. virginica	0	0	36

Tabela 3: Tabela pomyłek dla zbioru treningowego z uwzględnieniem wielomianów stopnia 2




Rysunek 3: Prognozy dla zbioru treningowego dla rozszerzonej przestrzeni cech

Na podstawie wyników z Tabeli 3 oraz Rysunku 3 widzimy, że model poradził sobie bardzo dobrze z klasyfikacją na zbiorze treningowym. Dla rozszerzonej przestrzeni cech skuteczność modelu dla danych treningowych wynosi 99.05% (błąd klasyfikacji wynosi 0.95%).

	setosa	versicolor	virginica
pred. setosa	14	0	0
pred. versicolor	0	17	0
pred. virginica	0	1	13

Tabela 4: Tabela pomyłek dla zbioru testowego z uwzględnieniem wielomianów stopnia 2



Rysunek 4: Prognozy dla zbioru testowego dla rozszerzonej przestrzeni cech

Na podstawie macierzy pomyłek (Tabela 4) oraz Rysunku 4 widzimy, że model osiągnął bardzo wysoką skuteczność również na zbiorze testowym. Dla danych testowych skuteczność modelu wynosi 97.78% (błąd równy 2.22%).

Rozszerzenie przestrzeni cech o składniki wielomianowe stopnia 2 znacząco poprawiło skuteczność modelu. Zarówno na zbiorze treningowym, jak i testowym, model osiągnął bardzo wysoką skuteczność.

2 Porównanie metod klasyfikacji.

2.1 Wybór i zapoznanie się z danymi.

Dane *Glass* pochodzą z pakietu *mlbench*. Zbiór tych danych zawiera informacje o składzie chemicznym różnych rodzajów szkła. Dane te zostały uzyskane na podstawie kryminalistycznych badań powypadkowych. Został on udostępniony przez Friendricha Leischa pod koniec lat 90. XX wieku.

Wczytujemy i dołączamy dane *Glass* z pakietu *mlbench*.

Zbiór tych danych składa się z 214 obserwacji i 10 cech. Tymi cechami są:

- **RI** (numeric; zakres: 1.51115-1.53393) - współczynnik załamania światła
- **Na** (numeric; zakres: 10.73-17.38) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek sodu
- **Mg** (numeric; zakres: 0.00-4.49) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek magnezu
- **Al** (numeric; zakres: 0.29-3.50) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek aluminium
- **Si** (numeric; zakres: 69.81-75.41) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek krzemu
- **K** (numeric; zakres: 0.00-6.21) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek potasu
- **Ca** (numeric; zakres: 5.43-16.19) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek wapnia
- **Ba** (numeric; zakres: 0.00-3.15) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek baru
- **Fe** (numeric; zakres: 0.00-0.51) - informacja o tym, jaki procent całkowitej masy dla danej próbki szkła stanowi tlenek żelaza
- **Type** (factor; 6 poziomów: 1, 2, 3, 5, 6, 7) - informacja o typie szkła (etykieta klasy)

Z danych wynika, że mamy 6 klas, a informację o przynależności obiektu do konkretnej klasy przechowuje zmienna **Type**.

Zbiór danych *Glass* nie posiada żadnych braków danych. Występują natomiast dane zduplikowane, tj. wiersz nr 40 jest duplikatem wiersza nr 39. Obecność jednego duplikatu w zbiorze nie zaburzy znacząco naszych obliczeń, dlatego nie będziemy go usuwać.

Dane *Glass* nie posiadają żadnych nietypowych kodowań. W Tabeli 5 przedstawione są poziomy i wartości unikalne dla zmiennej **Type**. Wynika z niej, że zmienna ta nie posiada

żadnych niestandardowych kodowań wartości brakujących, ponieważ liczba jej poziomów pokrywa się z listą przyjmowanych przez nią wartości.

W Tabeli 6 znajdują się wskaźniki sumaryczne dla zmiennych ilościowych. Wartości te nie wskazują na występowanie jakichkolwiek nietypowych kodowań.

Zmienna	Wartości	Poziomy
Type	1, 2, 3, 5, 6, 7	1, 2, 3, 5, 6, 7

Tabela 5: Porównanie wartości unikalnych z poziomami dla zmiennej Type

	Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
RI	1.51	1.52	1.52	1.52	1.52	1.53
Na	10.73	12.91	13.30	13.41	13.83	17.38
Mg	0.00	2.11	3.48	2.68	3.60	4.49
Al	0.29	1.19	1.36	1.44	1.63	3.50
Si	69.81	72.28	72.79	72.65	73.09	75.41
K	0.00	0.12	0.56	0.50	0.61	6.21
Ca	5.43	8.24	8.60	8.96	9.17	16.19
Ba	0.00	0.00	0.00	0.18	0.00	3.15
Fe	0.00	0.00	0.00	0.06	0.10	0.51

Tabela 6: Wskaźniki sumaryczne dla zmiennych ilościowych

Wszystkie zmienne mają przypisane odpowiednie typy, w tym także zmienna **Type**, która zgodnie z faktem, że jest etykietą klas, jest zmienną typu factor.

2.2 Cel analizy.


Celem niniejszego projektu jest przeprowadzenie wielokryterialnej analizy porównawczej wybranych metod klasyfikacji oraz schematów oceny dokładności na przykładzie zbioru danych *Glass*. Badaniu poddamy trzy klasyczne podejścia klasyfikacyjne: metodę k -najbliższych sąsiadów (k -NN), drzewa klasyfikacyjne oraz naiwny klasyfikator bayesowski. Ewaluacja modeli zostanie dokonana w oparciu o analizę macierzy pomyłek oraz porównanie stabilności błędów klasyfikacji przy jednokrotnym podziale danych na zbiór uczący i testowy oraz przy użyciu zaawansowanych technik resamplingu, takich jak walidacja krzyżowa oraz bootstrap. Zbadamy także, jaki wpływ na dokładność klasyfikacji mają różne kombinacje zmiennych wykorzystane do konstrukcji klasyfikatorów oraz dobór parametrów dla poszczególnych metod.

2.3 Wstępna analiza danych.

Zacznijmy od zbadania liczebności poszczególnych klas zbioru *Glass*

	1	2	3	5	6	7
Liczebność	70	76	17	13	9	29

Tabela 7: Tabela przedstawiająca liczebność poszczególnych klas



Rysunek 5: Wykres przedstawiający częstości poszczególnych klas

W analizowanym zbiorze rozkład klas jest zaburzony. Posiadamy 6 klas ponumerowanych od 1 do 7 za wyjątkiem 4. Możemy zaobserwować istotne dysproporcje w liczebności poszczególnych grup (Tabela 7 oraz Rysunek 5). Przykładowo grupa nr 2 jest najliczniejsza i liczy 76 obserwacji, zaś klasa nr 6 jest najmniejszą klasą i zawiera tylko 9 obserwacji.

Gdybyśmy przyporządkowali wszystkie obiekty do jednej, najliczniej występującej klasy, wówczas błąd klasyfikacji wyniósłby 0.645. Jest on bardzo wysoki i świadczy to o sporej ilości obserwacji, które są innej niż najliczniejsza grupa klasy.


Do przeprowadzenia analizy wybieramy wyłącznie cechy ilościowe. Przyjrzyjmy się teraz wariancom tych cech.

	Wariancja
RI	0.000
Na	0.667
Mg	2.081
Al	0.249
Si	0.600
K	0.425
Ca	2.025
Ba	0.247
Fe	0.009


Tabela 8: Tabela wariancji dla poszczególnych zmiennych numerycznych

Przyglądając się Tabeli wariancji (Tabela 8) dla poszczególnych cech, możemy zauważyć występujące różnice w zmienności. Największą wariancją charakteryzuje się zmienna **Mg**, zaraz po niej zmienna **Ca**. Najmniejszą wariancją zaś cechuje się zmienna **RI**. Pozostałe cechy mają wariancję z przedziału 0.0-0.7, więc największym zróżnicowaniem tak naprawdę charakteryzują się tylko dwie zmienne.

Dla lepszego zobrazowania zmienności przyjrzyjmy się również wykresom pudełkowym tych zmiennych.




Rysunek 6: Wykresy pudełkowe dla zmiennych ilościowych przed standaryzacją



Rysunek 7: Wykresy pudełkowe dla zmiennych ilościowych po standaryzacji


Rysunki 6 oraz 7 utwierdzają nas w przekonaniu, że dla zbioru danych *Glass* konieczna będzie standaryzacja w przypadku niektórych algorytmów klasyfikacyjnych. Rozkłady mocno się między sobą różnią, więc dla uzyskania jak najlepszych wyników przy próbie klasyfikacji danych metodą k -najbliższych sąsiadów, standaryzacja będzie niezbędna.

Sprawdźmy teraz, które zmienne charakteryzują się najlepszymi zdolnościami dyskryminacyjnymi. W tym celu rozważmy wykresy rozrzutu cech ilościowych względem zmiennej jakościowej **Type**.



Rysunek 8: Wykresy rozrzutu dla poszczególnych zmiennych ilościowych względem zmiennej Type

Zobaczmy również analogiczne wykresy pudełkowe.



Rysunek 9: Wykresy pudełkowe dla poszczególnych zmiennych ilościowych względem zmiennej Type

Przyglądając się Rysunkom 8 oraz 9 możemy zauważyć, że cechą o stosunkowo dobrej zdolności dyskryminacyjnej jest zmienna **A1**. Każde z pudełek umiejscowione jest na nieco innym poziomie, co zdecydowanie pozwala odróżnić od siebie obserwacje należące do klas 1-3 a 5 i 7. Klasy nr 6 nie da się niestety wyróżnić przez małą liczebność oraz wysokie rozproszenie. Do zbioru dobrze dyskryminujących cech możemy także zaliczyć zmienną **Mg**, ponieważ różniła klasy 1-3 od klas 5-7. Warto także wspomnieć o zmiennych **Na** oraz **K**, które dobrze oddzielają klasy 1-5 od 6-7. Ciekawym rozkładem cechuje się zmienna **Ba**. W jej przypadku możemy jednoznacznie wyróżnić tylko obserwacje kwalifikujące się do 7. klasy. Pozostałe zmienne charakteryzują się bardzo słabą zdolnością dyskryminacyjną - ich rozkłady przenikają się i niektóre z obserwacji mogłyby być zakwalifikowane do każdej z 6 dostępnych klas.

Powtarzający się wzorec podziału klas na dwie grupy (głównie 1-3 i 5-7) sugeruje w tym przypadku występowanie korelacji pomiędzy zmiennymi, co może mieć negatywny wpływ na działanie niektórych metod klasyfikacji.

2.4 Ocena dokładności klasyfikacji i porównanie metod.

Zajmiemy się teraz oceną dokładności klasyfikacji. Oryginalny zbiór podzielimy zatem na część treningową i testową w proporcji 2:1. Porównamy ze sobą trzy różne metody klasyfikacji danych, mianowicie metodę najbliższych sąsiadów, drzew klasyfikacyjnych oraz naiwny klasyfikator bayesowski. Metoda najbliższych sąsiadów jest metodą wrażliwą na różnice w zmienności, więc model dla k -NN zbudujemy na wystandaryzowanym zbiorze *Glass*. Pozostałe metody będą standardowo budowane na oryginalnym zbiorze danych.

	1	2	3	5	6	7
pred. 1	41	9	5	0	0	0
pred. 2	4	39	3	2	1	2
pred. 3	1	1	4	0	0	0
pred. 5	0	1	0	4	0	0
pred. 6	0	0	0	0	6	0
pred. 7	0	0	0	1	0	18

Tabela 9: Macierz pomyłek dla metody k-najbliższych sąsiadów przy użyciu funkcji `knn()` z pakietu `class` dla zbioru uczącego

	1	2	3	5	6	7
pred. 1	20	8	4	0	1	2
pred. 2	4	16	0	1	0	0
pred. 3	0	0	1	0	0	0
pred. 5	0	0	0	3	0	0
pred. 6	0	2	0	0	1	0
pred. 7	0	0	0	2	0	7

Tabela 10: Macierz pomyłek dla metody k -najbliższych sąsiadów przy użyciu funkcji `knn()` z pakietu `class` dla zbioru testowego

Tabele 9 i 10 przedstawiają macierze pomyłek dla zbioru treningowego i testowego. Prezentują one podział obserwacji na klasy za pomocą metody najbliższych sąsiadów (dla $k = 5$) przy użyciu funkcji `knn()` z pakietu `class` oraz ich pierwotną klasę. Z macierzy oraz z błędów klasyfikacji wynoszących odpowiednio 0.211 oraz 0.333 dla zbioru uczącego oraz testowego (Tabela 19) wynika, że dla zbioru treningowego metoda k -NN poradziła sobie lepiej, tzn. mniej przypadków dopasowała nieprawidłowo. Mimo wszystko błąd jest dalej stosunkowo wysoki.

	1	2	3	5	6	7
pred. 1	40	10	6	0	0	1
pred. 2	4	38	5	2	1	1
pred. 3	2	1	1	0	0	0
pred. 5	0	1	0	5	0	0
pred. 6	0	0	0	0	6	0
pred. 7	0	0	0	0	0	18

Tabela 11: Macierz pomyłek dla metody k -najbliższych sąsiadów przy użyciu funkcji `ipredknn()` z pakietu `ipred` dla zbioru uczącego

	1	2	3	5	6	7
pred. 1	19	7	3	0	1	2
pred. 2	4	16	1	2	0	0
pred. 3	1	1	1	0	0	0
pred. 5	0	1	0	3	0	0
pred. 6	0	1	0	0	1	0
pred. 7	0	0	0	1	0	7


Tabela 12: Macierz pomyłek dla metody k -najbliższych sąsiadów przy użyciu funkcji `ipredknn()` z pakietu `ipred` dla zbioru testowego

Tabelki 11 oraz 12 prezentują macierze pomyłek również dla metody k -najbliższych sąsiadów (przy $k = 5$), jednak tym razem przy użyciu funkcji `ipredknn()` z pakietu `ipred`. Porównując macierze dla zbioru uczącego dla funkcji `knn()` oraz `ipredknn()` możemy zaobserwować, że dla

tej drugiej funkcji model gorzej dopasował klasy, co potwierdza również błąd klasyfikacyjny wynoszący 0.239 (Tabela 19). Analogicznie dzieje się dla zbioru testowego. Tutaj również dla funkcji *ipredknn()* model poradził sobie gorzej (błąd równy 0.347), co także potwierdzają macierze. Jednakże dla obu funkcji zbiór treningowy charakteryzuje się mniejszym błędem niż zbiór testowy.

Obie funkcje powinny zwrócić przybliżone wyniki. Zauważone zatem różnice mogą wynikać z faktu, że różne implementacje funkcji mogą mieć inne reguły rozstrzygania “remisów”, np. gdy w otoczeniu jest po równo sąsiadów z różnych klas. Różnice mogą także wynikać z tego, że funkcje prawdopodobnie minimalnie inaczej traktują odległości przy identycznych współrzędnych.

Rysunek 10 pokazuje, w jaki sposób drzewa klasyfikacyjne rozdzielają obserwacje do poszczególnych klas dla zbioru *Glass* przy zachowaniu domyślnych parametrów. Z Rysunku wynika, że niestety tej metodzie nie udało się dopasować żadnych obserwacji do klasy nr 6. Dzieje się tak ze względu na niską liczebność tej klasy (zbiór nie jest zbalansowany) i trudność w przypisaniu obserwacji do poszczególnych klas przy pomocy dostępnych cech.



Rysunek 10: Wykres przedstawiający drzewo klasyfikacyjne przy zachowaniu domyślnych parametrów

	1	2	3	5	6	7
pred. 1	35	5	3	0	0	0
pred. 2	9	40	4	0	4	1
pred. 3	2	2	5	0	0	0
pred. 5	0	2	0	7	3	0
pred. 6	0	0	0	0	0	0
pred. 7	0	1	0	0	0	19

Tabela 13: Macierz pomyłek dla drzew klasyfikacyjnych dla zbioru uczącego

	1	2	3	5	6	7
pred. 1	17	4	0	0	1	1
pred. 2	5	20	3	1	1	1
pred. 3	1	2	2	0	0	0
pred. 5	0	0	0	4	0	0
pred. 6	0	0	0	0	0	0
pred. 7	1	0	0	1	0	7

Tabela 14: Macierz pomyłek dla drzew klasyfikacyjnych dla zbioru testowego

Macierze pomyłek 13 oraz 14 przedstawiają do jakiej klasy drzewa klasyfikacyjne dopasowały obserwacje i czy pokrywają się one z oryginalną klasyfikacją. Uwzględniając błędy klasyfikacyjne, wynoszące kolejno 0.254 i 0.306 dla zbiorów treningowego i testowego (Tabela 19), możemy wnioskować, że dla metody drzew klasyfikacyjnych model ponownie lepiej dopasował obserwacje dla zbioru uczącego niż dla zbioru testowego. Błąd dla zbioru testowego dla drzew klasyfikacyjnych jest dotychczas najniższym uzyskanym do tego zbioru.

	1	2	3	5	6	7
pred. 1	43	36	11	0	0	0
pred. 2	1	7	0	3	0	0
pred. 3	1	1	1	0	0	0
pred. 5	0	3	0	1	0	0
pred. 6	1	3	0	3	7	4
pred. 7	0	0	0	0	0	16

Tabela 15: Macierz pomyłek dla naiwnego klasyfikatora bayesowskiego dla zbioru uczącego

	1	2	3	5	6	7
pred. 1	22	19	4	0	0	1
pred. 2	1	2	0	0	0	0
pred. 3	1	1	0	0	0	0
pred. 5	0	0	0	1	0	0
pred. 6	0	4	1	4	2	2
pred. 7	0	0	0	1	0	6

Tabela 16: Macierz pomyłek dla naiwnego klasyfikatora bayesowskiego dla zbioru testowego

Tabele 15 i 16 przedstawiają macierze pomyłek dla naiwnego klasyfikatora bayesowskiego. Porównując macierze dla tej metody z macierzami dla innych metod, możemy dostrzec, że ten sposób klasyfikacji nie poradził sobie najlepiej z tymi danymi. Znaczna część obserwacji została nieprawidłowo dopasowana do klasy, o czym świadczą również wysokie błędy klasyfikacyjne sięgające 0.472 oraz 0.542 dla zbioru uczącego i zbioru testowego (Tabela 19).

	1	2	3	5	6	7
pred. 1	45	29	5	0	0	0
pred. 2	0	13	0	0	0	0
pred. 3	1	4	7	0	1	0
pred. 5	0	4	0	7	0	0
pred. 6	0	0	0	0	3	0
pred. 7	0	0	0	0	3	20

Tabela 17: Macierz pomyłek dla naiwnego klasyfikatora bayesowskiego z uwzględnieniem jądrowej estymacji gęstości dla zbioru uczącego

	1	2	3	5	6	7
pred. 1	21	16	4	0	1	1
pred. 2	0	3	0	1	0	0
pred. 3	3	4	1	0	0	1
pred. 5	0	1	0	4	0	1
pred. 6	0	2	0	0	0	1
pred. 7	0	0	0	1	1	5

Tabela 18: Macierz pomyłek dla naiwnego klasyfikatora bayesowskiego z uwzględnieniem jądrowej estymacji gęstości dla zbioru testowego

Tabele 17 oraz 18 także zawierają macierze pomyłek dla naiwnego klasyfikatora bayesowskiego, ale z uwzględnieniem jądrowej estymacji gęstości. Przyglądając się macierzom, możemy zauważyć, że model ten poradził sobie nieco lepiej niż klasyczny klasyfikator, co potwierdzają również błędy klasyfikacyjne (Tabela 19). Dla zbioru treningowego uzyskaliśmy błąd wynoszący 0.331. Dla zbioru testowego otrzymaliśmy zaś błąd wysokości 0.528, co w połączeniu ze stosunkowo “niskim” wynikiem dla zbioru uczącego może świadczyć o przeuczeniu modelu (overfitting).

	Zbiór uczący	Zbiór testowy
Błędy dla k-NN dla funkcji <code>knn()</code>	0.211	0.333
Błędy dla k-NN dla funkcji <code>ipredknn()</code>	0.239	0.347
Błędy dla drzew klasyfikacyjnych	0.254	0.306
Błędy dla NB	0.472	0.542
Błędy dla NB - kernel	0.331	0.528

Tabela 19: Tabela zawierająca błędy dla zbiorów uczących i testowych dla różnych algorytmów klasyfikacji

Dla każdej z testowanych metod klasyfikacji zbiór uczący charakteryzuje się lepszym dopasowaniem obserwacji do klas niż zbiór testowy. Metodą, która osiągnęła najlepszą skuteczność, jest metoda drzew klasyfikacyjnych. Świadczy o tym niska różnica pomiędzy błędem na zbiorze uczącym a na zbiorze testowym, wynosząca 5.203 punktów procentowych oraz najniższy uzyskany na zbiorze testowym błąd klasyfikacyjny. Różnice dla pozostałych metod oscylują między około 7, a 20 punktami procentowymi. Niższe błędy klasyfikacyjne dla zbioru uczącego uzyskaliśmy tylko dla metody k -najbliższych sąsiadów. Naiwny klasyfikator bayesowski nie poradził sobie dobrze z tym zbiorem danych. Dla jego klasycznej wersji uzyskaliśmy najwyższe błędy. Stało się tak ze względu na to, że zakłada on niezależność cech, podczas gdy dla tego zbioru mamy prawdopodobnie do czynienia z silnymi korelacjami pomiędzy składnikami chemicznymi szkła. Dla wersji uwzględniającej jądrową estymację gęstości możemy wnioskować, że doszło do przeuczenia modelu ze względu na wysoką różnicę pomiędzy błędami uzyskanymi na zbiorze treningowym i testowym, wynoszącą dokładnie 19.679 punktów procentowych.

Skupmy się teraz na porównaniu tych metod w oparciu o bardziej skomplikowane schematy oceny dokładności, tj. schemat walidacji krzyżowej, bootstrap oraz bootstrap .632+.

	Cross-validation	Bootstrap	Zaaw. bootstrap
Błędy dla k-NN dla funkcji <code>knn()</code>	0.336	0.358	0.321
Błędy dla k-NN dla funkcji <code>ipredknn()</code>	0.341	0.364	0.317
Błędy dla drzew klasyfikacyjnych	0.327	0.357	0.295
Błędy dla NB	0.621	0.602	0.588
Błędy dla NB - kernel	0.416	0.425	0.360

Tabela 20: Tabela zawierająca błędy dla różnych schematów oceny dokładności dla różnych algorytmów klasyfikacji


Otrzymane wyniki reprezentują uśredniony błąd klasyfikacji na próbach testowych dla rozważanych algorytmów przy użyciu zaawansowanych metod estymacji. Dla walidacji krzyżowej wybraliśmy podział na 10 podzbiorów, a dla obu wersji bootstrapu wybraliśmy 50-krotne losowanie zbioru uczącego. Z Tabeli 20 wynika, że dla różnych schematów otrzymaliśmy nieco inne wyniki, tzn. dla walidacji krzyżowej najniższe błędy osiągnęliśmy dla drzew klasyfikacyjnych (przy zachowaniu domyślnych parametrów). Klasyczny bootstrap uzyskał niemal takie same wyniki dla metody drzew klasyfikacyjnych oraz dla metody k -NN dla funkcji `knn()`

(przy $k = 5$). Zaawansowany bootstrap zaś najmniejsze błędy również uzyskał dla drzew klasyfikacyjnych. Ogólnie najniższe wartości błędów osiągnęliśmy przy użyciu schematu bootstrap .632+. Dla drzew klasyfikacyjnych błąd ten wyniósł 0.295, co jest wartością bardzo zbliżoną do najniższego błędu testowego uzyskanego przy pojedynczym. Sugeruje to, że w analizowanym przypadku wariant .632+ najtrafniej oceniał rzeczywistą zdolność generalizacyjną modeli, skutecznie korygując pesymistyczne obciążenie standardowego bootstrapu. Techniki wielokrotnego próbkowania “wygładziły” błędy, stabilizując je dla najlepszych modeli (k -NN oraz drzewa) na poziomie około 0.29-0.37. Dla zaawansowanych schematów oceny dokładności najskuteczniejszymi metodami okazały się więc drzewa klasyfikacyjne oraz metoda k -najbliższych sąsiadów, analogicznie jak dla pojedynczego podziału na zbiór uczący i testowy. Kluczowa różnica polega jednak na stabilności i wiarygodności oceny - zaawansowane schematy uśredniają wyniki z wielu prób, eliminując ryzyko wyciągnięcia błędnych wniosków na podstawie pojedynczego, przypadkowo fortunnego bądź niefortunnego podziału danych.

2.5 Różne parametry i różne podzbiory cech.

Sprawdźmy teraz, jak dobór parametrów oraz różne kombinacje zmiennych wpływają na skuteczność modeli dla poszczególnych metod klasyfikacji.

Przeanalizujemy wpływ liczby sąsiadów k na model k -NN z wykorzystaniem funkcji `ipredknn()`. Dla funkcji `knn()` wyniki są identyczne, dlatego pomijamy obliczenia.




Rysunek 11: Wpływ liczby sąsiadów na błąd metody k -NN

Na Rysunku 11 widzimy, że najmniejszy błąd klasyfikacji metody k -NN równy 0.285 osiągamy dla liczby sąsiadów $k = 3$.

Teraz na podstawie wniosków z podpunktu c) rozważmy 3 kombinacje podzbiorów:

1. zawierający wszystkie zmienne,
2. zawierający 5 zmiennych o najlepszej zdolności dyskryminacyjnej: **Mg**, **Al**, **Na**, **K**, **Ba**,
3. zawierający 3 zmienne o najlepszej zdolności dyskryminacyjnej: **Mg**, **Al**, **Ba**.




Rysunek 12: Wpływ liczby sąsiadów na błąd metody k -NN dla różnych podzbiorów cech

Liczba sąsiadów (k)	Wszystkie zmienne	5 najlepszych cech	3 najlepsze cechy
1	0.308	0.374	0.374
2	0.294	0.397	0.379
3	0.285	0.266	0.374
4	0.308	0.341	0.360
5	0.360	0.332	0.346
6	0.341	0.322	0.318
7	0.346	0.322	0.336
8	0.322	0.341	0.318
9	0.364	0.336	0.322
10	0.364	0.327	0.336
11	0.350	0.332	0.318
12	0.369	0.346	0.322
13	0.355	0.360	0.313
14	0.393	0.374	0.308
15	0.355	0.397	0.318

Tabela 21: Błędy klasyfikacji metody k-NN dla różnych podzbiorów zmiennych (10-fold Cross-Validation)

Na podstawie Rysunku 12 oraz Tabeli 21 widzimy, że najmniejszy błąd klasyfikacji równy około 0.266 osiąga model uwzględniający 5 zmiennych o najlepszej zdolności dyskryminacyjnej dla liczby sąsiadów $k = 3$. Dla wyższych wartości k błąd ten jednak rośnie. Model 3, uwzględniający 3 najlepiej rozróżniające zmienne, dla małej liczby sąsiadów radzi sobie zdecydowanie gorzej, jednak dla wyższych wartości k okazuje się najbardziej stabilny i utrzymuje się na niskim poziomie błędów. Model 1, uwzględniający wszystkie zmienne, jest bardzo skuteczny dla małych wartości k , jednak wraz ze wzrostem liczby sąsiadów, jego błąd wzrasta.

Teraz sprawdzimy, jak wybór parametru cp wpływa na skuteczność drzewa klasyfikacyjnego. Zastosujemy najpierw metodę, która polega na wybraniu cp , dla którego błąd krosvalidacji jest najmniejszy.



Rysunek 13: Wpływ parametru cp na skuteczność drzewa klasyfikacyjnego


	CP	Błąd CV ($xerror$)
1	0.20652	1.087
2	0.07246	0.594
3	0.05797	0.601
4	0.03623	0.471
5	0.03261	0.478
6	0.02174	0.449
7	0.01449	0.464
8	0.01087	0.442
9	0.01000	0.471

Tabela 22: Parametr złożoności cp a błędy krosvalidacji dla drzewa

Rysunek 13 obrazuje nam jak wybór parametru złożoności cp wpływa na skuteczność drzewa. Z Tabeli 22 odczytujemy, że najmniejszy błąd klasyfikacji równy około 0.442 otrzymujemy dla cp równego 0.01087.

Teraz do znalezienia optymalnej wartości parametru cp zastosujemy regułę **1SE** (jednego błędu standardowego). Odczytujemy najmniejszy błąd krosvalidacyjny ($xerror.min$) oraz jego odchylenie standardowe ($xstd.min$). Następnie szukamy największej wartości cp (odpowiadającej najmniejszej złożoności modelu), dla której spełniony jest warunek:

$$xerror < xerror.min + xstd.min$$



Rysunek 14: Przycięcie drzewa na podstawie kryterium kosztu-łożoności

Reguła **1SE** umożliwiła nam znalezienie optymalnej wartości parametru $cp = 0.03623$, dla której względny błąd krosvalidacyjny wynosi 0.471. Jest to błąd większy, niż ten otrzymany poprzednią metodą. Reguła ta, kosztem nieco wyższego błędu, pozwala nam na zachowanie dobrej jakości klasyfikacji, przy znacznym uproszczeniu modelu. Na Rysunku 14 widzimy drzewo po przycięciu na podstawie kryterium kosztu-łożoności.

Porównajmy teraz, jak wybór zestawu cech wpływa na skuteczność drzewa klasyfikacyjnego. Wybieramy takie same podzbiory jak poprzednio w przypadku metody k -NN.

Zbiór wszystkich zmiennych	Podzbiór 5 najlepszych cech	Podzbiór 3 najlepszych cech
0.294	0.327	0.322

Tabela 23: Błędy klasyfikacji drzew dla różnych podzbiorów zmiennych (10-fold Cross-Validation)

W Tabeli 23 widzimy, że najmniejszy błąd klasyfikacji równy 0.294 osiągamy dla podzbioru uwzględniającego wszystkie zmienne, jednak wybór mniejszego podzbioru nie wpływa aż tak znacząco na skuteczność modelu. Dla pozostałych podzbiorów osiągamy również dość satysfakcjonujący wynik - błąd równy 0.327 oraz 0.322.

Porównajmy teraz jak wybór cech wpływa na skuteczność klasyfikatora bayesowskiego. Ponownie rozważamy ten sam podział na podzbiory jak poprzednio.

Zbiór wszystkich zmiennych	Podzbiór 5 najlepszych cech	Podzbiór 3 najlepszych cech
0.640	0.533	0.598

Tabela 24: Błędy klasyfikacji Naive-Bayes dla różnych podzbiorów zmiennych (10-fold Cross-Validation)

Na podstawie wyników z Tabeli 24 widzimy, że najmniejszy błąd klasyfikacji osiągamy dla podzbioru uwzględniającego 5 cech o największej zdolności dyskryminacyjnej.

Zbadajmy teraz to samo, ale dla klasyfikatora bayesowskiego z uwzględnieniem estymatora jądrowej gęstości.

Zbiór wszystkich zmiennych	Podzbiór 5 najlepszych cech	Podzbiór 3 najlepszych cech
0.407	0.472	0.491

Tabela 25: Błędy klasyfikacji Naive-Bayes z uwzględnieniem estymatora jądrowego dla różnych podzbiorów zmiennych (10-fold Cross-Validation)

Na podstawie wyników z Tabeli 25 widzimy, że najniższy błąd klasyfikacji osiągamy dla podzbioru uwzględniającego wszystkie zmienne. Dla mniejszych podzbiorów błąd klasyfikatora jest większy.

2.6 Końcowe wnioski - podsumowanie.

Na podstawie przeprowadzonej analizy, możemy sformułować następujące wnioski:

- Metoda k -NN osiąga najlepsze wyniki dla podzbioru uwzględniającego 5 zmiennych o najlepszej zdolności dyskryminacyjnej: **Mg**, **Al**, **Na**, **K**, **Ba** dla liczby sąsiadów równej $k = 3$. Dla wyższych wartości parametru k model jest najbardziej stabilny i optymalny dla podzbioru 3 najlepszych zmiennych: **Mg**, **Al** oraz **Ba**.
- Drzewa klasyfikacyjne osiągają najlepszą skuteczność, kiedy uwzględnimy w modelu wszystkie zmienne, jednak dobór mniejszych podzbiorów nie wpływa drastycznie na wyniki. Znaleźliśmy wartość parametru $cp = 0.01087$, dla której błąd krosvalidacji jest najmniejszy oraz $cp = 0.03623$, dzięki któremu możemy znacznie uprościć drzewo niewielkim kosztem straty dokładności modelu.
- Standardowy klasyfikator bayesowski osiąga najlepsze wyniki dla podzbioru 5 najlepszych cech.
- Klasyfikator bayesowski z uwzględnieniem estymatora jądrowego osiąga najlepsze wyniki, gdy bierzemy pod uwagę wszystkie cechy.

- Dla analizowanego zbioru *Glass* najlepszą skuteczność (błąd krosvalidacji równy 0.266) osiąga model k -NN z parametrem $k = 3$ dla podzbioru 5 zmiennych o najlepszej zdolności dyskryminacyjnej. Drzewa klasyfikacyjne również osiągają wysoką skuteczność (błąd 0.294) dla pełnego zbioru danych. Klasyczny naiwny klasyfikator bayesowski osiągnął najgorsze rezultaty.
- Wybór schematu oceny dokładności nie wpłynął istotnie na ogólne wnioski dotyczące skuteczności modeli, ponieważ każdy z nich najwyżej plasował algorytm drzew klasyfikacyjnych oraz metodę k -najbliższych sąsiadów. Z kolei najniższą skutecznością niezmiennie charakteryzowały się klasyczny klasyfikator bayesowski oraz jego wariant z estymatorem jądrowym gęstości.